

BÀI CHỨNG MINH TOÁN HỌC CỦA CÔNG THỨC MASH DISTANCE

Xác định tỷ lệ đột biến nucleotide D từ chỉ số tương đồng k -mer Jaccard J

1. Đặt Bài Toán Tiến Hóa Di Truyền

Giả sử ta so sánh hai chuỗi DNA A và B có tỷ lệ đột biến nucleotide trung bình giữa hai chuỗi là D (tức là xác suất để một vị trí nucleotide bất kỳ bị đột biến thay đổi là D). Ta sử dụng các đoạn k -mer có độ dài cố định là k nucleotide để so sánh tập hợp trình tự.

2. Bước 1: Xác Suất Bảo Tồn Một Đoạn k -mer (k-mer Conservation)

- Xác suất để một vị trí nucleotide đơn lẻ không bị đột biến (giữ nguyên) là $(1 - D)$.
- Do một đoạn k -mer gồm k nucleotide liên tiếp độc lập, xác suất để toàn bộ k vị trí trong đoạn k -mer đều không bị đột biến là:

$$P(k\text{-mer conserved}) = (1 - D)^k$$

3. Bước 2: Thiết Lập Mối Liên Hệ Với Chỉ Số Jaccard (J)

Theo mô hình xác suất MinHash (Fan et al., 2014; Ondov et al., 2016), tỷ lệ các đoạn k -mer chung xuất hiện ở cả hai chuỗi (chính là chỉ số Jaccard J) liên hệ với xác suất bảo tồn qua phương trình:

$$J = \frac{(1 - D)^k}{2 - (1 - D)^k}$$

Biến đổi đại số giải tìm $(1 - D)^k$ theo J :

$$J \cdot [2 - (1 - D)^k] = (1 - D)^k \quad \square \quad 2J - J \cdot (1 - D)^k = (1 - D)^k \quad \square \quad (1 - D)^k \cdot (1 + J) = 2J$$

$$(1 - D)^k = \frac{2J}{1 + J}$$

4. Bước 3: Lấy Logarithm Tự Nhiên ($\ln$) & Khai Triển Taylor

Lấy logarithm tự nhiên ($\ln$) ở cả hai vế:

$$\ln((1 - D)^k) = \ln\left(\frac{2J}{1 + J}\right) \quad \square \quad k \cdot \ln(1 - D) = \ln\left(\frac{2J}{1 + J}\right)$$

Áp dụng khai triển chuỗi Taylor cho hàm logarithm với tỷ lệ đột biến D nhỏ ($D \ll 1$):

$$\ln(1 - D) \approx -D \quad (\text{với } D \ll 1)$$

Thay xấp xỉ $\ln(1 - D) \approx -D$ vào phương trình trên ta được:

$$k \cdot (-D) = \ln\left(\frac{2J}{1 + J}\right) \quad \square \quad -k \cdot D = \ln\left(\frac{2J}{1 + J}\right)$$

KẾT LUẬN CUỐI CÙNG (CÔNG THỨC MASH DISTANCE)

$$D = -\frac{1}{k} \ln\left(\frac{2J}{1 + J}\right)$$

Tài Liệu Tham Khảo Trích Dẫn:

- Ondov, B. D., et al. (2016). Mash: fast genome and metagenome distance estimation using MinHash. Genome Biology, 17(1), 132. DOI: 10.1186/s13059-016-0997-x
- Fan, H., et al. (2014). An assembly-free method of phylogeny reconstruction using short-read sequencing data. BMC Genomics, 15(1), 835. DOI: 10.1186/1471-2164-15-835